細隙灯アライメントロボット

ロボットアームが細隙灯のジョイスティックを握り、カメラ画像だけで瞳孔に合わせる ― 模倣学習（BC・DAgger）による実装と評価

動画：（提出時に記入）　／　コード：https://github.com/hideaki647/slitlamp-robot　／　実行環境：MuJoCo 3.15・PyTorch 2.11（CPU）・Docker
※ 患者はすべて合成CG。実在の患者の画像・情報、人間の医師の操作データは一切使っていない。

> 細隙灯顕微鏡の診察では、検者がジョイスティックで本体を動かし、患者の瞳孔に光軸とピントを合わせる（アライメント）。本課題では、遠隔診療を見据え、**既存の細隙灯を改造せず、人の手のためのジョイスティックをロボットアームがそのまま握って操作する**システムを物理シミュレータ MuJoCo 上に構築した。シミュレータだけが知る瞳孔の真の位置を使う「先生」（P制御）のお手本から、**カメラ画像だけを入力とする「生徒」**（CNN）を行動クローニング（BC）と DAgger で学習した。未知の合成患者50人で、生徒は**成功率100%、収束0.44秒、最終誤差0.027mm**を達成した。さらに5つの拡張実験（左眼・モジュール型との比較、画像の遅れ、両眼の切替、瞬き、前後のピント合わせ）を行い、End-to-End 学習の**近道学習**、遅れによる振動（制御理論の予測と一致）、**手順の外の状況での誤った自信**などの弱点と、その対策を示した。特にピント合わせでは、眼科医が「手前に引いた状態から奥へ押す」手順を守ることが、画像だけでは決まらない前後の向きを補っていることが、実験から裏づけられた。

1. 背景と目的

細隙灯顕微鏡は眼科診療の基本の検査機器であり、検者は片手でジョイスティックを倒して本体を左右・前後に動かし、回して高さを合わせる。遠隔地での眼科診療や、検者の負担軽減のために、この位置合わせの自動化には価値がある。自動化の方法として専用の電動ステージを組み込む方法も考えられるが、普及している既存の機器をそのまま使えない。そこで本課題では、**人の手のための操作インタフェース（ジョイスティック）を、ロボットアームがそのまま握って操作する**構成をとった。

AIの役割は、**カメラ画像を見てジョイスティックをどう動かすかを決める方策（ポリシー）**である。手で設計した制御則（古典制御）ではなく、お手本からの模倣学習で方策を得る。眼科医の手技を「お手本 → 模倣」で学ばせるという構図は、医療現場での技能継承とも重なる。

目標は次の3点とした。(1) ロボットアームがジョイスティックを握り、指令どおりに細隙灯を動かせること。(2) 画像だけを見る学習済み方策で、未知の患者の瞳孔に合わせられること。(3) 実用化を見据え、学習方策の弱点（条件の変化、遅れ、瞬き、ピント）を実験で明らかにすること。

2. システム

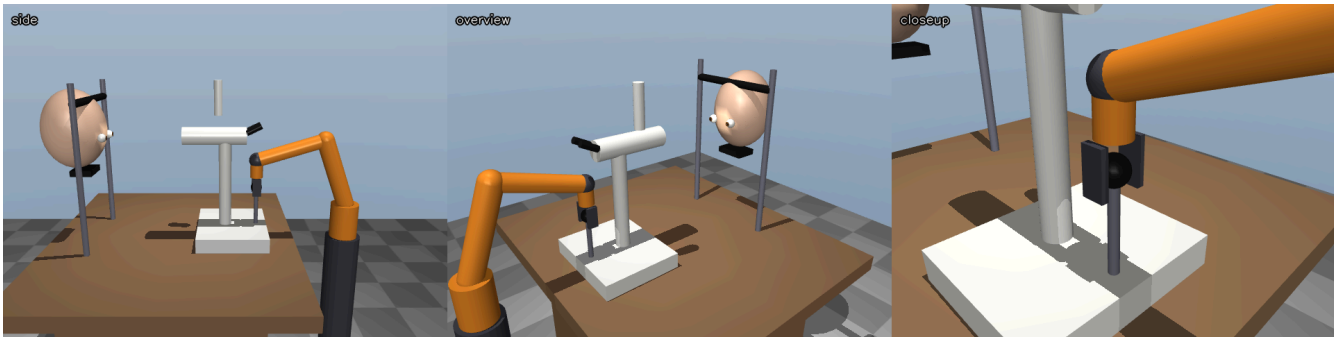


図1　シミュレータ上のシステム。左から側面・俯瞰・手元。6関節のロボットアーム（橙）が細隙灯のジョイスティックを握り、顎台の合成CGの患者に合わせる。

2.1 シーン

MuJoCo の設計図（MJCF）で、診察台・細隙灯（基台・支柱・鏡筒）・ジョイスティック・顎台・合成CGの頭部と両眼を作った。眼は半径12mmの球に虹彩・瞳孔の円盤を持ち、瞳孔の中心に目印（site）を置いた。鏡筒の先に**細隙灯カメラ**（検者が接眼レンズで見る視野に相当、視野角15°、96×96画素）と、スポットライトによる**細隙光**を付けた。

2.2 ジョイスティックと本体の連動

実機ではジョイスティックの傾きがリンク機構で本体の移動に、ハンドルの回転がネジで鏡筒の上下に変換される。これを MuJoCo の等式拘束で「本体の左右位置＝0.15 m/rad × 左右の傾き」「前後位置＝−0.15 m/rad × 前後の傾き」「鏡筒の高さ＝0.00318 m/rad × ハンドルの回転」として再現した（10°倒すと26mm、半回転で10mm）。簡略化として、実機の「大きな移動は台ごと滑らせる」は省き、傾き角と位置を一対一に対応させた。

2.3 ロボットアームと逆運動学

6関節のアーム（旋回・肩・肘と球面手首3軸）を検者側に置いた。方策の出力は「本体を $\Delta x, \Delta z$（拡張Hでは Δy も）[mm] 動かす」という差分の指令で、これを ①ジョイスティックの目標角 → ②ノブの目標の位置・姿勢 → ③減衰付き最小二乗法による逆運動学（$\Delta q = J^{T}(JJ^{T}+\lambda^{2}I)^{-1}e$）→ ④関節の位置制御、の順に変換する。把持は手とノブを溶接拘束（weld）で一体化した（「握った状態から開始」という簡略化）。モーターのゲインを調整し（kp/kv = 250/6）、指令への追従誤差は平均0.19mm・最大0.47mmとなった。

3. 方法

3.1 課題の設定

0.1秒ごと（10Hz）に「画像を見る → 指令を決める → 動かす」をくり返す。指令は1ステップ最大3mm。細隙灯は瞳孔から左右±15mm・上下±8mmずれた位置（平均9.6mm）から始め、**光軸と瞳孔中心のずれが1mm未満を5ステップ（0.5秒）保てたら成功**、5秒以内に成功しなければ失敗とする。評価は学習に使っていない合成患者50人（全方式で同じ50人）で行った。

3.2 先生（エキスパート）とお手本の収集

先生は、シミュレータだけが知る瞳孔中心の真の位置（**特権情報**）を使い、指令 = 0.5 × ずれ（P制御）で操作する。画像を見ないので実機では使えないが、必ず正確に合わせられる（成功率100%、収束0.43秒）。お手本は、合成患者3,000人について1.2秒（12ステップ）ずつ、画像と先生の指令の組を記録した（**3.6万組**、16並列で約5分）。患者ごとに頭の位置（左右±10mm・上下±8mm）、瞳孔の半径（1.5〜4.0mm）、虹彩の色（5色）、肌の色、照明の明るさ（×0.7〜1.3）を変えた（**ドメインランダム化**）。また、実行する指令にだけ標準偏差0.5mmのノイズを混ぜ、ずれた状態から戻る場面も集めた（**DART** [2]、記録するのはノイズなしの正解）。



図2　お手本の例（細隙灯カメラの96×96画像を拡大）。赤い矢印は先生の指令の向きと大きさ。患者ごとに虹彩・肌の色、瞳孔径、照明、位置が異なる。

3.3 生徒（学習方策）

生徒は96×96の画像だけを入力し、指令を直接出力する CNN である。畳み込み3層の後に**空間ソフトマックス** [3] で16個の特徴点の座標を取り出し、全結合層で指令を出す（約3万パラメータ、CPUで学習可能）。細隙灯カメラでは1mm ≒ 1.85画素で、合格範囲が約2画素しかないため、画素より細かい位置を読める空間ソフトマックスを採用した。

- **BC（行動クローニング）：**お手本の画像 → 先生の指令を教師あり学習で真似る（平均二乗誤差、40周、明るさ・色・コントラスト・ノイズのデータ拡張）。患者単位で1割を確認用に分けた。
- **DAgger** [1]：生徒が自分で操作し（500人×3秒）、通った場面すべてに先生が正解を付けて教材に足し、学び直す。4ラウンドで計9.6万組。BCの弱点である**分布シフト**（自分のずれで、お手本に無い見え方に入り込む）への対策。

4. 結果（基本課題）

表1　未知の患者50人での成功率 / 最終誤差 [mm]（収束時間は成功した回でどの方式も約0.41〜0.44秒）

方式	通常	暗い（×0.5）	明るい（×1.55）	灰色の虹彩	頭が大きくずれる
先生（特権情報）	100% / 0.008	100% / 0.010	100% / 0.010	100% / 0.010	100% / 0.010
生徒 BC	100% / 0.058	**84%** / 0.80	100% / 0.14	100% / 0.16	100% / 0.063
生徒 BC＋DAgger	100% / **0.027**	**100%** / 0.32	100% / 0.076	100% / 0.044	100% / 0.030

「暗い」「明るい」「灰色の虹彩」「頭が大きくずれる」は学習時の範囲の外の条件。

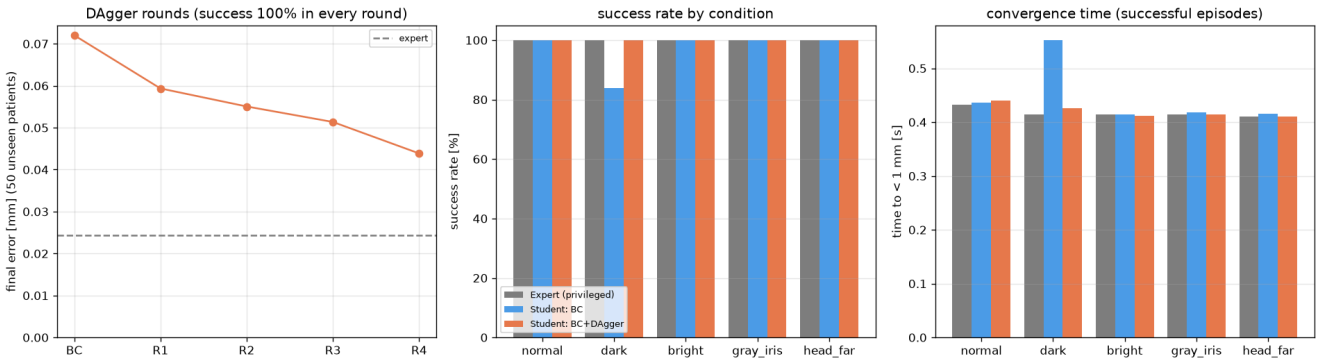


図3　左：DAgger のラウンドごとの最終誤差（どのラウンドも成功率100%）。中・右：条件別の成功率と収束時間。※この図はアームの手首の不具合（5.1節）を直す前の測定で、表1は修正後に測り直した値。

- **画像だけで、先生とほぼ同じ速さで合わせられた。**通常の条件で成功率100%、収束0.44秒（先生0.43秒）。特権情報を持つ先生 → 画像だけの生徒、という教え方が機能した。
- **DAgger の効果は精度と頑健さに表れた。**通常の条件では BC の時点で100%で、DAgger により最終誤差が約4割減った（BC 0.072 → R4 0.044mm、手首の修正前の測定）。暗い条件では成功率が改善し、200人で測り直しても 86% → 98% だった。ただし、DAgger の生徒はデータ量・学習量も多い（9.6万組 vs 3.6万組）ため、効果の一部はデータ量によるものの可能性がある。

5. 拡張実験

5.1 左眼への対応と、モジュール型との比較（近道学習）

右眼だけで学習した生徒は、**左眼を見せても左眼を無視して右眼まで約64mm移動した**（成功率0%）。生徒は「写った瞳孔を中央に合わせる」ではなく、顔の輪郭などを手がかりに「患者の右眼へ行く」を学んでいた。これは**近道学習** [5] の典型例である。対策として、(a) 右眼の画像を左右反転して学ぶデータ拡張は48%にとどまった（光源が片側に固定で、反転画像の光の向きが本物の左眼と逆になるため）。(b) 左眼のお手本も集めて学ぶと、両眼とも100%になった。シミュレータでは先生が新しい課題のお手本を自動で作れるので、これが最も確実で安価だった（収集7分＋学習46分）。なお、左眼の評価の途中で、アームの手首が可動範囲の端に当たる不具合を見つけて修正した。

比較として、学習を使わず、画像処理で瞳孔を検出して P制御で動かす**モジュール型**を作った（しきい値を暗い側から上げながら同じ領域を追跡し、虹彩の影とつながる直前で止める方法。お手本画像4,000枚で検出失敗0%）。

表2　End-to-End（生徒）とモジュール型の比較（成功率 / 最終誤差 [mm]）

方式	通常	暗い	左眼（学習なし）	失敗の仕方
モジュール型（校正あり）	100% / 0.16	86% / 1.72	**100%** / 0.16	瞳孔が見つからず止まる（暴走しない、理由が見える）
生徒 BC＋DAgger（右眼）	100% / **0.027**	**100%** / 0.32	**0%** / 57	自信を持って誤った場所（右眼）へ動く

End-to-End は精度が高い（特権情報のラベルで、照明による見かけのずれまで補正できる）一方、何を手がかりにしているかが見えず、学習の範囲外では自信を持って誤る。モジュール型は精度で劣るが、見ているもの（瞳孔の円）が明確で、範囲外でもそのまま使え、失敗は「見つからない」と分かる。医療機器としては、両者を組み合わせ、生徒の指令が検出した瞳孔と大きく食い違えば止める、といった**安全装置**が考えられる。

5.2 遅れ・ノイズへの強さ

実機で避けられない不完全さを、学習し直さずに試した。モーターの強さ（×0.5〜1.5）や画像のノイズ・ぼけでは全方式が100%を保った（毎回画像を見て直す閉ループ制御の強み）。一方、**観測の遅れ**では全方式がそろって崩れた

（0.1秒：100%、**0.2秒：8〜10%、0.3秒：0%**）。P制御のずれは

$$e[n+1] = e[n] - g \cdot e[n-k] \quad （g：ゲイン、k：遅れのステップ数）$$

に従い、特性方程式 $z^{k+1} - z^k + g = 0$ の根の大きさの最大値は $g = 0.5$ で 0.2秒 → 0.94、0.3秒 → **1.02（発散）**となり、実験と一致した（0.2秒はアーム自体の約0.1秒の反応の遅れが加わったと考えられる）。理論から「最も速く収まるゲイン」（0.2秒 → 0.15、0.3秒 → 0.11）を求め、方策の出力に倍率（0.3、0.22）を掛けると、**学習し直さずに全方式が100%に戻った**（収束は1.1〜1.5秒に延びる）。実機では、カメラ〜推論〜通信の遅れを0.1秒以内に抑えるか、測った遅れに合わせてゲインを下げる必要がある。

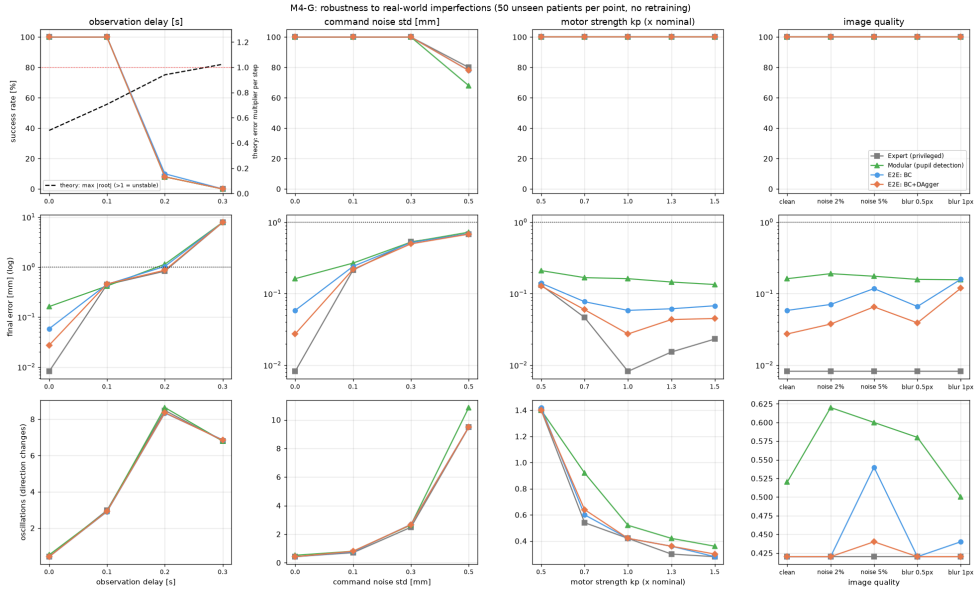


図4　遅れ・指令のばらつき・モーターの個体差・画像の質に対する成功率と最終誤差。遅れのグラフには理論の予測（根の大きさ）を重ねた。

5.3 右眼⇄左眼の切替（指示つきの方策）

両眼の間（約64mm）は細隙灯カメラの視野（横約52mm）より広く、片眼に合わせた状態では反対の眼が画面に写らない。そこで画像に加えて「右眼へ／左眼へ」の**指示**を入力する生徒（goal-conditioned policy）を作り、両眼の間の距離を56〜72mmでばらつかせたお手本（計13.2万組）で学習した。

表3　反対の眼へ移って合わせる（未知の患者50人ずつ）

方式	右眼→左眼	左眼→右眼	到達時間	最終誤差
先生	100%	100%	2.24〜2.26秒	0.006mm
決め打ち64mm移動＋モジュール型（学習なし）	100%	100%	2.41〜2.45秒	0.15mm
指示の無い生徒	0%	0%	—	64mm
指示つきの生徒	**100%**	**100%**	**2.25〜2.27秒**	0.05〜0.06mm

指示を1つ加えるだけで、画像だけでは決まらない課題が解け、移る速さは先生と同じだった。その場で合わせる精度も落ちなかった（0.05〜0.07mm）。

5.4 瞬き

右眼に上瞼・下瞼を作り、患者が瞬きをするようにした。先生は「瞳孔が隠れている間は待つ」とした。

表4　瞬き中の本体の動き（平均 / 最大）と、瞼の見た目だけの影響

方式	瞬き中の動き	瞼あり・瞬きなしの最終誤差
モジュール型（見つからなければ動かない）	0.06 / 0.30mm	0.30mm
BC＋DAgger（瞬き・瞼を知らない）	**0.54 / 0.87mm**	**0.24mm**（瞼なしでは0.027）
瞬きのお手本で学んだ生徒（1枚）	0.08 / 0.29mm	0.058mm
同（直前2枚も見る＝フレームスタック）	**0.05 / 0.13mm**	0.045mm

瞬きを知らない生徒は、瞳孔の見えない画像（学習の範囲外）で何らかの指令を出し、瞼が閉じている間に動いた（BC では最大1.8mm）。瞬きのお手本で学ぶと「待つ」を真似でき、直前の画像も見る生徒は、半分閉じた途中の画像で迷う最悪の場合を小さくした。また、**瞬きをしなくても、瞼があるだけで瞼を知らない生徒の精度が落ち**（0.027 → 0.24mm）、逆に瞼ありで学んだ生徒は瞼が無いと精度が落ちた。End-to-End の生徒は眼のまわりの見た目全体を手がかりにしており（5.1節と同じ性質）、実機では瞼の形・睫毛などのばらつきを学習データに含める必要がある。

5.5 前後のピント合わせ

深度画像から画素ごとの焦点からのずれを求め、ずれに比例したぼかし（1画素/mm）を加えて焦点ぼけを再現し、指令に前後（Δy、ジョイスティックの前後の傾き）を加えた。成功条件に「前後0.5mm未満」を追加した。眼科医（筆者）の臨床経験では、**手前に引いた状態から奥へ押してピントを合わせることが多い。**そこで先生のお手本は、焦点より3〜8mm手前から始めた（3,000人×1秒）。

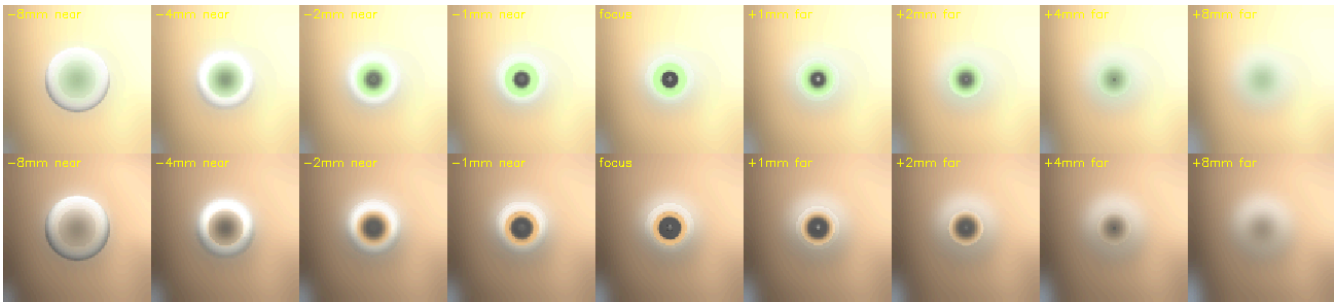


図5　焦点からのずれによる画像のぼけ（左から −8, −4, −2, −1, 0, +1, +2, +4, +8mm。− ＝近づきすぎ、＋＝手前すぎ）。近づきすぎても手前すぎても同じようにぼける（眼の写る大きさがわずかに変わるだけ）。

表5　前後のピント合わせ（未知の患者50人ずつ）

方式	手前から開始（臨床の手順）	近づきすぎから開始（学習にない）
先生	100%（0.47秒）	100%
生徒（1枚）	78%（0.51秒）	**0%**（最初に焦点から遠ざかった割合 100%）
生徒（直前2枚も見る）	**86%**（0.53秒）	16%（同 88%）

手前から始めると、生徒は左右・上下を毎回合わせ、失敗はすべて焦点の0.5〜1.2mm手前で止まったものだった（焦点付近ではぼけの差がごくわずかで、「ほぼ合っている」と「合っている」を画像から見分けにくい）。一方、**近づきすぎた位置から始めると、生徒はさらに奥へ押し込み**、26〜34mm奥の可動範囲の端まで行った。ぼけは前後で対称なので、1枚の画像からは「手前すぎ」と「奥すぎ」を区別できず、お手本の「ぼやけていたら奥へ押す」をそのまま実行したためである。直前の画像も見る生徒は、ぼけが増えていくことに気づいて引き返せた例がわずかにあった。

6. 考察

1. **特権情報を持つ先生 → 画像だけの生徒という教え方は、少ない計算資源（CPUのみ）で、先生と同等の速さ・0.03mm程度の精度の方策を作れた。**先生さえ書ければ、左眼や両眼の切替、瞬きのような新しい課題のお手本

も数分で自動生成できる点が、シミュレータでの模倣学習の強みである。

2. **End-to-End の生徒は、人が意図しない手がかりを使う。**顔の輪郭から右眼の位置を推定する（5.1）、瞼の有無だけで精度が変わる（5.4）など、学習の範囲を少し外れると「自信を持って誤る」。モジュール型との組み合わせ（検出結果との食い違いで止める）や、見た目のばらつきを広く含むお手本が必要である。
3. **実用上の最大の課題は遅れで、これは学習ではなく制御の問題である。**どの方式も同じように崩れ、制御理論で予測・対策（ゲインの調整）ができた。学習方策も閉ループ制御系の一部として設計する必要がある。
4. **お手本の設計が、そのまま生徒の安全性になる。**先生が瞬きの間は「待つ」と、生徒も待つ（5.4）。逆に、先生が手前からしか始めないと、生徒は近すぎる状況でも奥へ押し込む（5.5）。
5. **眼科医の手順は、画像の曖昧さを補っている。**ぼけだけでは前後の向きが決まらないが、検者は「手前に引いた状態から奥へ押す」という手順で向きを決めている。同様に、細隙灯で水晶体 → 前房 → 角膜後面 → 角膜表面とピントを手前へ送るときも、検者は次にどちらへ動かすかを知っている。学習した生徒は手順の前提ごと覚えており、前提が崩れると誤った。手順（次はどの面か、どちらから来たか）を指示として与える方策（5.3と同じ仕組み）は、この曖昧さを解消する自然な方法であり、熟練者の暗黙知をロボットに伝える入口になると考える。

7. 限界と今後の課題

- **シミュレーションと実際の差（Sim-to-Real）：**眼は球と円盤の簡略なCGで、角膜・水晶体、角膜反射、睫毛、眼球運動・頭の揺れは無い。焦点ぼけは深度画像に基づく後処理の近似で、スリット光の光学切片は再現していない。実際の眼の画像での検証が必要である。
- **操作の簡略化：**把持は溶接拘束、ジョイスティックは傾き角＝位置の一対一対応とした。実機の摩擦・がた・台ごとの移動は今後の課題である。
- **お手本は人間の医師ではない：**先生は特権情報を使うP制御であり、熟練者の操作の「くせ」や判断は含まない。実機では人間のお手本、または人が監督する DAgger が必要になり、手間が大きい。
- **評価の規模：**多くの比較は50人での評価で、2〜3人の差は偶然でも起こりうる。DAgger の効果とデータ量の効果も切り分けていない。
- **今後：**ピント合わせの DAgger（焦点の手前で止まる問題）、層ごとのピント送り（次の面を指示として与える方策）、モジュール型と組み合わせた安全装置、実機での検証。

参考文献

1. S. Ross, G. Gordon, J. A. Bagnell. A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning. AISTATS, 2011.（DAgger）
2. M. Laskey, J. Lee, R. Fox, A. Dragan, K. Goldberg. DART: Noise Injection for Robust Imitation Learning. CoRL, 2017.
3. S. Levine, C. Finn, T. Darrell, P. Abbeel. End-to-End Training of Deep Visuomotor Policies. JMLR 17(39), 2016.（空間ソフトマックス）
4. E. Todorov, T. Erez, Y. Tassa. MuJoCo: A physics engine for model-based control. IROS, 2012.
5. R. Geirhos et al. Shortcut learning in deep neural networks. Nature Machine Intelligence 2, 665–673, 2020.
6. J. Tobin et al. Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World. IROS, 2017.